UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

PRIMER AVANCE DEL PROYECTO FINAL

Catálogo de PlazaVea: análisis de precios y descuentos para el consumidor

CURSO:
ANÁLISIS COMPUTACIONAL DE DATOS

ESTUDIANTES:

Aliaga Mena, Lucas Armando 201810550

Bazán Meléndez, Valeria 202410443

Cuadros Villegas, Denilson Jermai 202510232

Torres Ccencho, Leo Alexander 202410078

Torres Chafloque, Enrique Eusebio 202510601

LIMA – PERÚ
2026

Índice

1. Identificación 2
2. Contexto 2
3. Objetivos 2
    3.1. Objetivo General 2
    3.2. Objetivos Específicos 3
4. Dataset Preliminar 3
5. Alcance 4
6. Fuentes de Datos 4
7. Estrategia 4
8. Viabilidad 5

1. Identificación

El proyecto se dividió en seis partes, para que cada integrante pudiera avanzar por su cuenta sin esperar a que otro terminara primero. Las dos primeras partes eran las más urgentes, porque el resto del grupo dependía de sus resultados para poder trabajar:

- **Valeria Bazán Meléndez** — Fuente y reconocimiento técnico: revisó cómo la página de PlazaVea entrega sus datos (si el catálogo carga con HTML simple o si depende de JavaScript), qué información trae cada producto y qué permite el archivo robots.txt del sitio.
- **Denilson Jermai Cuadros Villegas** — Motor de scraping: escribió el script en Python que extrae cada producto de una categoría (nombre, precio, marca, descuento, entre otros), maneja la paginación del catálogo y reintenta cuando algo falla. También redactó el presente informe.
- **Lucas Armando Aliaga Mena** — Ejecución masiva: tomó el script ya probado y lo corrió sobre las once categorías del catálogo hasta superar los 1000 registros exigidos, guardando un archivo parcial por categoría y consolidando todo en un único CSV crudo.
- **Enrique Eusebio Torres Chafloque** — Limpieza y calidad de datos: convirtió el CSV crudo en un dataset listo para analizar, corrigiendo precios, tildes, duplicados y dejando los valores nulos por debajo del 10 % que exige la rúbrica.
- **Leo Alexander Torres Ccencho** — Diccionario de datos: documentó el significado de cada variable del dataset limpio (descripción, tipo, tamaño máximo, valores posibles y unidad) en el formato oficial del curso.

2. Contexto

PlazaVea es una de las cadenas de supermercados más grandes del Perú y publica en su página web el catálogo completo de productos con los precios que están vigentes en ese momento. Esta información es útil porque permite construir, a partir de una fuente real y pública, un conjunto de datos sobre precios del mercado peruano: cuánto cuesta un producto, si tiene descuento, de qué marca es y en qué categoría se ubica.

El problema de fondo es que esta información no está disponible en un formato fácil de analizar: está repartida en cientos de páginas web y cambia todos los días. Para un consumidor, esto significa que es difícil saber si un descuento es realmente conveniente, qué categorías suelen tener más ofertas o cuánto varía el precio de un mismo tipo de producto entre marcas. Hoy esa comparación se hace a ojo, producto por producto. Si se logra capturar el catálogo de forma ordenada, es posible convertirlo en información útil para que el consumidor tome mejores decisiones de compra. Además, esta fuente no ofrece una API pública, por lo que obtenerla exige aplicar técnicas de web scraping.

3. Objetivos

3.1. Objetivo General

Construir y analizar un dataset de más de 1000 productos del catálogo de supermercado de PlazaVea, obtenido mediante web scraping, para brindar al consumidor información clara sobre precios, descuentos y marcas que le permita tomar decisiones de compra mejor informadas.

3.2. Objetivos Específicos

Los objetivos corresponden al proyecto completo. Los dos primeros construyen la base de datos y no son fines en sí mismos: son las condiciones que hacen posible responder las preguntas de los objetivos 3 a 6. Sin un catálogo reunido en una sola tabla no hay nada que comparar, y sin una limpieza documentada cualquier comparación sería poco confiable. En este primer avance se desarrollan los objetivos 1 y 2.

1. **Reunir en una sola tabla comparable** los precios que hoy están dispersos en cientos de páginas del catálogo de PlazaVea, extrayendo más de 1000 productos con Selenium y BeautifulSoup sobre el contenido renderizado, con cobertura equilibrada entre categorías, respetando el robots.txt y sin usar APIs internas.
2. **Dejar ese dataset en condiciones de ser analizado sin riesgo de conclusiones erróneas**, mediante un proceso de limpieza documentado que unifique formatos, elimine duplicados reales sin borrar presentaciones distintas de un mismo producto, mantenga los nulos por debajo del 10 % por columna, descarte las variables cuya exactitud no pueda verificarse, y genere las variables derivadas — descuento porcentual y ahorro en soles— que requieren los objetivos siguientes. Cada decisión queda registrada en una bitácora de limpieza.
3. Identificar las categorías con mayor frecuencia de descuentos, para orientar al consumidor sobre dónde encontrar más ofertas.
4. Calcular el ahorro real en soles de cada descuento, para distinguir las ofertas significativas de las simbólicas.
5. Comparar precios entre marcas de productos similares, para identificar las alternativas más económicas.
6. Determinar en qué categorías se concentra el precio exclusivo con tarjeta Oh!, para saber dónde conviene usarla.

Tabla 1: Avance de los objetivos por etapa

Objetivos	**Etapa**	**Estado**
1 – 2	Primer avance	Completado
3 – 6	Siguientes avances	Pendiente

4. Dataset Preliminar

El resultado de la extracción es un archivo CSV crudo con 1506 filas y 11 columnas, repartidas en once categorías del supermercado (abarrotes, bebidas, lácteos, cuidado personal, frutas y verduras, carnes y pescados, desayunos, quesos y fiambres, panadería, congelados y limpieza). Tras la etapa de limpieza, el dataset final queda con 1491 productos en diez categorías. Cada fila representa un producto y cada columna es un atributo:

- `sku`: identificador del producto, tomado de su URL.
- `nombre`: nombre completo del producto tal como aparece en el sitio.
- `marca`: marca del producto.
- `categoria`: categoría del supermercado a la que pertenece.
- `precio_venta`: precio actual, en soles.
- `precio_regular`: precio sin descuento, en soles.
- `tiene_precio_oh`: si el producto tiene un precio especial con la tarjeta Oh! (verdadero o falso).
- `descuento_pct`: porcentaje de descuento calculado.
- `url_producto`: enlace a la página del producto.
- `url_imagen`: enlace a la imagen del producto.
- `fecha_extraccion`: fecha y hora en que se extrajo el dato.

Las columnas de precio, descuento, marca, categoría y tarjeta Oh! son las que permiten responder los objetivos 3 a 6 en las siguientes entregas.

Tabla 2: Muestra de tres registros del dataset crudo

Nombre	**Marca**	**Categoría**	**P. venta**	**P. regular**	**Desc. %**
Galletas Saladas FIELD Soda Paquete 6un	FIELD	Abarrotes	S/ 3.50	S/ 3.90	10.26
Gomas AMBROSOLI Cerebros Bolsa 250g	AMBROSOLI	Abarrotes	S/ 14.50	S/ 14.50	0.00
Galletas FIELD Choko-Soda Paquete 6un	FIELD	Abarrotes	S/ 6.30	S/ 7.20	12.50

Este es el dataset crudo, tal como sale directamente del scraping. La etapa de limpieza corrige detalles como el formato del texto, los nombres de columnas poco precisos y los registros duplicados.

5. Alcance

El proyecto extrae únicamente el catálogo público de productos de supermercado de PlazaVea: nombre, marca, categoría, precios y descuento. No se recolecta ningún dato personal de usuarios ni información de cuentas, porque esa información ni siquiera está disponible en las páginas de catálogo que se visitaron.

Se extrajeron once categorías del rubro “Supermercado” del sitio, elegidas a mano para asegurar que la suma de productos superara cómodamente los 1000 registros que pide la rúbrica; tras la limpieza se conservaron diez, porque Limpieza devolvió muy pocos registros. Quedan fuera del alcance otras secciones del sitio, como “Electro, hogar y más”. Tampoco se revisa el stock disponible de cada producto más allá de si su precio se muestra en cero.

El análisis se orienta al consumidor: busca describir cómo están distribuidos los precios y descuentos en un momento determinado, no predecir precios ni evaluar ventas. Como los datos son una foto de una fecha y una zona de entrega, los resultados describen patrones del catálogo en ese momento. Detectar tendencias en el tiempo requeriría repetir la extracción en varias fechas, lo que se plantea como una extensión posible del proyecto.

6. Fuentes de Datos

La única fuente de datos usada es el sitio web de PlazaVea (https://www.plazavea.com.pe), una cadena de supermercados peruana. Es una fuente peruana, pública y de libre acceso: no requiere iniciar sesión ni pagar para ver el catálogo y los precios.

Se eligió porque publica precios reales del mercado, organizados por categoría, con información suficiente (nombre, marca, precio, descuento) como para construir un dataset completo sin depender de encuestas o datos simulados. Al no ofrecer una API pública para descargar esta información, es una fuente adecuada para aplicar la técnica de web scraping que pide el curso. Además, es el mismo catálogo que consulta un comprador real, por lo que los resultados reflejan los precios y ofertas a los que el consumidor tiene acceso.

7. Estrategia

Antes de escribir cualquier código se hicieron dos comprobaciones. Primero, se revisó robots.txt para confirmar que las rutas de catálogo usadas no estaban restringidas. Segundo, se comparó el HTML que entrega el servidor directamente (usando la librería requests) contra el HTML que se ve después de que el navegador ejecuta su JavaScript: el primero llegaba sin productos y el segundo sí los traía. Esa prueba confirmó que el catálogo se arma con JavaScript, así que la técnica elegida fue Selenium (que abre un navegador real y espera a que la página cargue) combinado con BeautifulSoup (que

recorre el HTML ya cargado para sacar cada dato). No se usó Scrapy porque esa librería no ejecuta JavaScript por sí sola.

Para la paginación se probó primero hacer scroll infinito, pero se descubrió que tiene un techo fijo de más o menos 60 a 110 productos sin importar cuánto se scrollee. La solución fue usar la paginación real del sitio, que funciona con un parámetro en la URL (?page=N), navegando página por página hasta que una página ya no traiga productos nuevos.

Como plan de contingencia ante cambios en la página, cada dato (nombre, precio, marca, etc.) se busca probando varias opciones de selector en orden, no solo una: si el sitio cambia una clase CSS, el script prueba la siguiente opción en vez de fallar por completo. También hay reintentos con espera creciente cuando una página no carga, y se guarda un archivo por categoría apenas termina, para no perder el trabajo si algo falla más adelante en la corrida.

Como plan de contingencia frente a restricciones de acceso, antes de programar se revisó robots.txt: si alguna categoría necesaria hubiera estado bloqueada ahí, el plan era reemplazarla por otra categoría equivalente del mismo catálogo. Durante la extracción real no se recibió ningún bloqueo permanente; aun así, el script está preparado para eso: si una página no carga, reintenta con una espera cada vez más larga, y si el problema persiste solo en una categoría, esa categoría se descarta sin detener la extracción de las demás (cada categoría se guarda en su propio archivo apenas termina).

8. Viabilidad

El proyecto es viable porque usa únicamente herramientas gratuitas y de código abierto: Python, Selenium, BeautifulSoup y pandas, además de Google Chrome, que ya suele estar instalado. No se necesitó pagar por ningún servicio ni pedir acceso especial al sitio.

En cuanto al tiempo, dividir el trabajo en seis partes permitió que varios integrantes avanzaran en paralelo: mientras se probaba el motor de scraping en una sola categoría, ya se podía ir preparando la limpieza y el diccionario de datos con esa muestra pequeña. La corrida completa sobre las once categorías demoró unas horas, principalmente por las pausas entre páginas y categorías que se agregaron a propósito para no saturar el servidor. El resultado, un archivo crudo con 1506 filas generado en una sola corrida y 1491 productos tras la limpieza, confirma que la estrategia elegida sí alcanza para cumplir el mínimo de 1000 registros que pide la rúbrica dentro del tiempo disponible para esta entrega.

Exploración preliminar. Una revisión inicial del dataset limpio confirma que permite responder los objetivos planteados. El 48.2 % de los productos tiene descuento, pero con grandes diferencias entre categorías: desde 80.0 % en Cuidado Personal hasta 12.0 % en Frutas y Verduras. Además, el 34.7 % de los descuentos es menor al 10 %, y la

mediana del ahorro es de apenas S/ 1.76 , lo que indica que muchas ofertas son simbólicas. Solo el 6.4 % de los productos tiene precio con tarjeta Oh!.